

Lab 8 - Costos de GCP y qué te falta para conectarte

- Practicar TODOS los labs de la parte 2 en modo real cuesta menos de 2 USD en total (casi todo cae en capas gratuitas). Si tu cuenta es nueva, Google da 300 USD de crédito por 90 días.
- Lo único caro de este curso es Cloud Composer (~400 USD/mes aunque no haga nada) y Vertex AI Vector Search (cobra por nodo encendido 24/7). Los labs NO los crean: se explican y se prueban local.
- Un presupuesto de GCP AVISA pero NO DETIENE el gasto. Para cortar el gasto: terraform destroy.
- Precios en USD, región us-central1, verificados el 29 de septiembre de 2026. Cambian seguido: confirma en cloud.google.com/pricing y en la calculadora (cloud.google.com/products/calculator).

1. Matriz de costos por servicio

Servicio	Para qué en los labs	Cómo cobra	Precio (USD)	Gratis cada mes	Costo de practicar	Riesgo y cómo evitarlo
Vertex AI - Gemini	Labs 11-19: generar, analizar, convertir, documentar	Por millón de tokens de entrada y de salida (salida incluye 'thinking')	Flash-Lite 3.1: 0.25 / 1.50	No (crédito de 300 USD si eres nuevo)	< 1 USD	Un agente en ciclo sin límite. Usa MAX_PASOS/MAX_INTENTOS y max-instances
Vertex AI - Embeddings	Labs 13 y 17: vectores para RAG	Por millón de tokens de entrada	gemini-embedding-001: 0.15	No	< 0.01 USD	Re-embeber todo en cada arranque. Guarda el índice (lab 13 lo cachea)
BigQuery - consultas	Lab 17: SQL migrado, dry run, VECTOR_SEARCH	On-demand: por TiB leído (mínimo 10 MB por consulta)	6.25 USD / TiB	1 TiB	0 USD	SELECT * sobre tablas enormes. Usa dry run, particiones y columnas concretas
BigQuery - almacenamiento	Tablas ventas, auditoría, conocimiento	Por GiB al mes (lógico)	0.02 activo / 0.01 largo plazo	10 GiB	0 USD	Datos que nadie borra. Particiona y pon expiración
Cloud Storage	Labs 18 y 20: entrada/, resultados/, tmp/	Por GB al mes + operaciones	~0.020 USD / GB-mes (Standard)	5 GB-mes (us-central1)	0 USD	Buckets olvidados. Terraform pone borrado automático a 30 días
Cloud Run	Lab 19: API del migrador	vCPU-segundo + GiB-segundo + peticiones (solo mientras atiende)	0.000024 vCPU-s / 0.0000025 GiB-s / 0.40 por millón	180,000 vCPU-s; 360,000 GiB-s; 2M peticiones	0 USD	min-instances > 0 cobra 24/7. Deja 0 y pon max-instances
Cloud Functions (2a gen)	Lab 18: analiza cada .sas que se sube	Igual que Cloud Run (corre sobre Cloud Run)	Igual que Cloud Run	Comparte la de Cloud Run	0 USD	Ciclo infinito si escribe en la carpeta que la dispara (el lab filtra entrada/)
Cloud Build + Artifact Registry	Construir imágenes al desplegar labs 18-19	Minutos de build / GB de imágenes guardadas	Build ~0.006 USD/min; AR 0.10 USD/GB-mes	2,500 min de build; 0.5 GB en AR	< 0.10 USD	Imágenes viejas acumuladas. Borra versiones antiguas
Eventarc + Pub/Sub	Disparador Storage -> Function (lab 18)	Por volumen de mensajes	Centavos por millón de eventos	10 GiB de Pub/Sub	0 USD	Mínimo
Cloud Logging	Lab 21: logs JSON de cada llamada	Por GiB ingerido	0.50 USD / GiB	50 GiB por proyecto	0 USD	Loguear prompts completos a gran escala. Loguea métricas, no textos enteros
Dataflow	Lab 20 (opcional): el pipeline Beam en la nube	vCPU-hora + GB-hora de los workers	~0.056 USD vCPU-h (batch)	No	~0.05 USD por corrida	Jobs de streaming que quedan corriendo. Cancela con gcloud dataflow jobs cancel

Servicio	Para qué en los labs	Cómo cobra	Precio (USD)	Gratis cada mes	Costo de practicar	Riesgo y cómo evitarlo
Cloud Composer 3	Lab 20 (opcional): el DAG de Airflow	DCU-hora del entorno, corra o no corra nada	0.06 USD / DCU-hora	No	~13 USD por día que exista	CARO: ~400 USD/mes. Si lo creas, destrúyelo el mismo día
Vertex AI Vector Search	No se usa (se explica como alternativa)	Por nodo/hora del índice desplegado	Desde ~70 USD/mes por nodo	No	0 USD (no se crea)	Índice desplegado olvidado. Para aprender usa BigQuery VECTOR_SEARCH
Presupuesto (Billing Budgets)	infra/presupuesto.tf: alertas 50/90/100%	Gratis	0	-	0 USD	Moneda distinta a la de tu cuenta de facturación = error al aplicar

2. Modelos Gemini en Vertex AI (USD por millón de tokens)

Modelo / opción	Entrada	Salida	Cuándo usarlo
gemini-3.1-flash-lite	0.25	1.50	Default de los labs. Barato: clasificar, extraer, documentar
gemini-3-flash	0.50	3.00	Balance calidad/precio
gemini-3.8-flash	0.75 (1.50 desde ene-2027)	3.75 (7.50 desde ene-2027)	El Flash más nuevo: buena opción para convertir código
gemini-3.5-flash	1.50	9.00	Flash de alta capacidad
gemini-3.1-pro	2.00 (4.00 >200K tokens)	12.00 (18.00 >200K)	Programas complejos, macros, razonamiento
gemini-2.5-flash (lab7)	0.30	2.50	SE RETIRA ~16-20 oct 2026: migra lab7 a un modelo 3.x
Batch API	-50 %	-50 %	Migraciones masivas que no necesitan respuesta inmediata
Context caching	hasta -90 % en entrada repetida	-	El mismo prompt de sistema + reglas en miles de llamadas

3. Proyección para el proyecto real: migrar 5,000 programas SAS

Supuesto: por programa ~40K tokens de entrada y ~10K de salida (analista + convertidor con 2 intentos promedio + documentador + juez). Solo tokens de IA; la infraestructura con uso moderado suma decenas de USD al mes. Mide con 10-20 programas reales (lab 21) antes de presupuestar.

Modelo	USD por programa	USD total (5,000)	USD total con Batch API (-50%)
gemini-3.1-flash-lite	0.025	125	63
gemini-3.8-flash (precio intro)	0.068	338	169
gemini-3.1-pro	0.200	1,000	500

4. Qué te falta para conectar los labs a GCP

Requisito	Cómo se consigue	Comando / dónde	Lo verifica
Cuenta de Google Cloud con facturación	Alta en console.cloud.google.com (pide tarjeta; 300 USD de crédito)	gcloud billing accounts list	-
Proyecto dedicado al lab	Crear proyecto y ligarle la facturación	gcloud projects create ID ; gcloud billing projects link ID --billing-account=...	lab 10
gcloud CLI	Instalar Google Cloud SDK	cloud.google.com/sdk/docs/install	lab 10
Credenciales locales (ADC)	Login de aplicación (sin llaves JSON)	gcloud auth application-default login	lab 10
APIs y recursos	Terraform crea APIs, bucket, dataset, tablas, cuenta de servicio y permisos	cd infra ; terraform init ; terraform apply	labs 17-19
Rol para ti	Owner/Editor del proyecto o, mínimo, Vertex AI User + BigQuery User	IAM y administración > IAM	lab 10
Configuración	Copiar .env.example a .env y poner MODO=real y tu GCP_PROJECT_ID	parte2_gcp/.env	lab 10
Modelo disponible	Confirmar que el ID de GEMINI_MODEL existe en tu región	Vertex AI > Model Garden	lab 10
Terraform (opcional pero recomendado)	Instalar Terraform >= 1.6	developer.hashicorp.com/terraform/install	infra/
Presupuesto con alertas	billing_account_id en terraform.tfvars	infra/presupuesto.tf	-

Fuentes

- Vertex AI / Gemini: cloud.google.com/vertex-ai/generative-ai/pricing y ai.google.dev/gemini-api/docs/pricing
- BigQuery: cloud.google.com/bigquery/pricing | Cloud Run y Functions: cloud.google.com/run/pricing
- Cloud Composer: cloud.google.com/composer/pricing | Retiro de Gemini 2.5: notas de versión de Vertex AI
- Estimaciones de terceros usadas para contrastar: cloudzero.com (Vertex AI pricing 2026), nops.io (Composer)